UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
Centro Multidisciplinar Pau dos Ferros
Departamento de Engenharias e Tecnologia

Lista 1

Sistemas Inteligentes

PAM0466 · Semestre 2026.2

Docente: Pedro Thiago Valério de Souza

Sumário

1 Fundamentos de aprendizagem **3**
Questão 1 — Modalidades de aprendizagem . . . 3
Questão 2 — Escolha do tipo de aprendizagem . . . 3
Questão 3 — Batch e on-line . . . 3
Questão 4 — Parâmetros e hiperparâmetros . . . 4
Questão 5 — Modelos e instâncias . . . 4
Questão 6 — Treinamento, validação e teste . . . 4

2 Regressão e regularização **5**
Questão 7 — Suposições da regressão linear . . . 5
Questão 8 — Coeficiente de determinação . . . 5
Questão 9 — Regularização Ridge . . . 6
Questão 10 — Intensidade da regularização . . . 6
Questão 11 — Escala dos atributos na regressão . . . 6
Questão 12 — Seleção de atributos com Lasso . . . 7

3 Avaliação e classificação **7**
Questão 13 — Limitações da acurácia . . . 7
Questão 14 — AUC-ROC . . . 8
Questão 15 — Validação cruzada K-Fold . . . 8
Questão 16 — Treinamento e latência de previsão . . . 8
Questão 17 — Classificação com k-NN . . . 9

4 Árvores de decisão **9**
Questão 18 — Estrutura de uma árvore de decisão . . . 9
Questão 19 — Entropia de Shannon . . . 10
Questão 20 — Impureza de Gini . . . 10
Questão 21 — Ganho de informação . . . 10
Questão 22 — Critérios de parada de árvores . . . 11
Questão 23 — Atributos numéricos e limiares . . . 11

5 Clusterização e k-means **12**
Questão 24 — Clusterização e classificação . . . 12
Questão 25 — Qualidade de uma clusterização . . . 12
Questão 26 — Algoritmo k-means . . . 13
Questão 27 — Limitações do k-means . . . 13
Questão 28 — Matriz de dissimilaridade e distâncias . . . 14
Questão 29 — Escalonamento antes do k-means . . . 15
Questão 30 — Três situações de falha do k-means . . . 15

1 Fundamentos de aprendizagem

Questão 1 | Modalidades de aprendizagem

Diferenciar os conceitos de aprendizado supervisionado, não supervisionado e aprendizagem por reforço.

Resposta.

- **Supervisionado:** aprende uma relação entre entradas $\mathbf{x}$ e saídas desejadas y a partir de exemplos rotulados. O objetivo é prever a saída de novas entradas. Inclui classificação (por exemplo, identificar spam) e regressão (prever um preço).
- **Não supervisionado:** recebe dados sem rótulos de saída e procura estruturas, padrões ou representações. Exemplos: agrupar clientes e reduzir a dimensionalidade dos dados.
- **Por reforço:** um agente interage com um ambiente, executa ações e recebe recompensas. Aprende uma política de ação para maximizar a recompensa acumulada ao longo do tempo, equilibrando exploração e aproveitamento do que já aprendeu.

A diferença central está no sinal de aprendizagem: respostas corretas por exemplo, estrutura dos dados ou recompensas decorrentes de ações.

Questão 2 | Escolha do tipo de aprendizagem

Qual tipo de algoritmo (aprendizado supervisionado, não supervisionado ou aprendizagem por reforço) você usaria para:

(a) possibilitar que um robô andasse por aí em lugares inexplorados?

(b) para segmentar seus clientes em diversos grupos?

(c) para detectar spam em uma caixa de e-mail?

Resposta.

(a) **Aprendizagem por reforço.** O robô aprende ações de navegação pela interação com o ambiente. Pode receber recompensas por avançar com segurança ou alcançar destinos e penalidades por colisões. É a escolha esperada para a aprendizagem da política de navegação.

(b) **Aprendizado não supervisionado.** Um algoritmo de clusterização identifica grupos de clientes com características semelhantes, sem precisar de categorias previamente rotuladas.

(c) **Aprendizado supervisionado.** Mensagens previamente rotuladas como spam ou não spam permitem treinar um classificador que atribua essas classes a novos e-mails.

Questão 3 | Batch e on-line

Diferenciar os conceitos de aprendizagem em batch e aprendizado on-line.

Resposta. Na **aprendizagem em batch**, o treinamento usa um conjunto de dados disponível em um determinado momento. Após o treinamento, o modelo permanece fixo até um novo processo de treinamento. Incorporar dados novos normalmente exige um novo ajuste com uma base atualizada.

Na **aprendizagem on-line**, o modelo é atualizado incrementalmente com novas amostras ou pequenos lotes. É útil em fluxos de dados, em situações com restrição de memória e quando a distribuição dos dados muda ao longo do tempo.

Aprendizagem on-line não significa necessariamente conexão à internet. Além disso, treinar um modelo em minilotes sobre uma base fixa não implica, por si só, aprendizagem on-line em produção.

Questão 4 | Parâmetros e hiperparâmetros

Qual a diferença entre parâmetro e hiperparâmetro de um modelo?

Resposta. Parâmetros são valores aprendidos a partir dos dados durante o treinamento, como os coeficientes e o intercepto de uma regressão.

Hiperparâmetros configuram a estrutura do modelo ou seu processo de aprendizagem e são escolhidos antes de cada ajuste. Exemplos: número de vizinhos k no k-NN, intensidade de regularização α e profundidade máxima de uma árvore.

Hiperparâmetros podem ser selecionados automaticamente por busca e validação cruzada. Ainda assim, diferem dos parâmetros estimados pelo algoritmo em cada treinamento.

Questão 5 | Modelos e instâncias

Qual a diferença entre algoritmos de aprendizado de máquina baseados em modelos e algoritmos baseados em instâncias?

Resposta. Algoritmos **baseados em modelos** ajustam uma representação geral da relação entre entradas e saídas. Na regressão logística, por exemplo, o treinamento estima coeficientes; as previsões usam esses coeficientes.

Algoritmos **baseados em instâncias** armazenam exemplos de treinamento e usam sua semelhança com uma nova entrada para realizar previsões. O k-NN classifica uma amostra consultando os vizinhos mais próximos.

Assim, nos métodos baseados em modelos, grande parte do trabalho ocorre no ajuste; nos baseados em instâncias, uma parcela importante ocorre na consulta. O k-NN também é um modelo preditivo, mas não ajusta previamente uma função paramétrica global.

Questão 6 | Treinamento, validação e teste

Qual o objetivo do conjunto de treinamento, conjunto de validação e conjunto de teste?

Resposta.

- **Treinamento:** estimar os parâmetros e aprender os padrões usados pelo modelo. Estatísticas de pré-processamento, como médias e desvios padrão, também devem ser estimadas com esses dados.
- **Validação:** comparar alternativas e escolher hiperparâmetros, atributos e outras decisões de modelagem. Pode ser implementada por uma divisão fixa ou por validação cruzada.
- **Teste:** avaliar o desempenho final em dados que não participaram do treinamento nem das decisões de seleção do modelo.

Usar repetidamente o teste para tomar decisões faz com que ele deixe de representar uma avaliação independente. As divisões também devem respeitar a estrutura dos dados, por exemplo, tempo ou grupos de indivíduos.

2 Regressão e regularização

Questão 7 | Suposições da regressão linear

Para que os estimadores de uma regressão linear sejam confiáveis, o modelo deve seguir certas suposições. Descreva pelo menos três delas (ex: linearidade, homocedasticidade, independência).

Resposta. Considere $y_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} + \varepsilon_i$. Entre as suposições relevantes estão:

1. **Linearidade da média condicional:** $\mathbb{E}[y \mid \mathbf{x}] = \beta_0 + \sum_j \beta_j x_j$. A linearidade é nos parâmetros; atributos transformados, como x^2, podem integrar o modelo.
2. **Exogeneidade:** $\mathbb{E}[\varepsilon \mid X] = 0$. O erro não deve conter um componente sistemático associado aos regressores. A omissão de uma variável relevante correlacionada com eles pode violar essa condição.
3. **Homocedasticidade:** $\mathrm{Var}(\varepsilon_i \mid X) = \sigma^2$. A variância dos erros é constante. Sua violação pode comprometer os erros padrão usuais e a eficiência dos estimadores.
4. **Independência dos erros:** erros de observações diferentes não dependem uns dos outros. Para os resultados de Gauss–Markov, a ausência de correlação entre eles é suficiente. Séries temporais frequentemente exigem atenção à autocorrelação.
5. **Ausência de multicolinearidade perfeita:** nenhuma coluna explicativa é combinação linear exata das demais. Isso permite identificar unicamente os coeficientes por mínimos quadrados.

A **normalidade dos erros** é uma hipótese adicional usada na inferência clássica exata em amostras pequenas. Não é necessária para que os estimadores de mínimos quadrados sejam não viesados sob exogeneidade.

Questão 8 | Coeficiente de determinação

O que representa o coeficiente de determinação R^2 em um modelo de regressão? Por que um R^2 muito próximo de 1 nem sempre garante que o modelo fará boas previsões em novos dados?

Resposta. Para respostas não constantes, define-se

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \overline{y})^2}.$$

Ele compara o erro quadrático do modelo com o erro de prever sempre a média das respostas avaliadas. No ajuste usual por mínimos quadrados com intercepto, representa a fração da variabilidade amostral explicada pelo modelo: $R^2 = 0{,}8$ corresponde a 80% dessa variabilidade.

Um R^2 próximo de 1 **no treinamento** pode resultar de sobreajuste: o modelo aprende também ruído e particularidades daquela amostra. Vazamento de dados e mudanças na distribuição também podem prejudicar previsões futuras. É necessário avaliar em dados independentes, usando, por exemplo, R^2, MAE e RMSE.

Em dados de teste, R^2 pode ser negativo: nesse caso, o modelo erra mais, em termos quadráticos, do que a referência baseada na média desses dados.

Questão 9 | Regularização Ridge

A regularização Ridge (L_2) adiciona um termo de penalidade à função de perda proporcional ao quadrado da magnitude dos coeficientes. Explique como esse método diminui a possibilidade de um overfitting.

Resposta. Uma forma da função objetivo Ridge é

$$\min_{\beta_0,\boldsymbol{\beta}} \left\{ \frac{1}{n} \sum_{i=1}^{n} (y_i - \beta_0 - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \alpha \sum_{j=1}^{p} \beta_j^2 \right\}.$$

A penalidade torna custoso obter um pequeno ganho no ajuste por meio de coeficientes muito grandes. Isso contrai os coeficientes, reduz a sensibilidade às flutuações do treinamento e tende a diminuir a variância do modelo, inclusive quando há atributos fortemente correlacionados.

Há uma troca entre viés e variância: a Ridge introduz viés, mas pode reduzir o erro em dados novos. O valor de α deve ser escolhido por validação. Regularização excessiva provoca subajuste. Usualmente, o intercepto não é penalizado e os atributos são padronizados antes do ajuste.

Questão 10 | Intensidade da regularização

Discuta o papel do hiperparâmetro de regularização α. O que acontece com o modelo quando $\alpha = 0$ e quando $\alpha \to \infty$?

Resposta. O hiperparâmetro $\alpha \geq 0$ controla o peso da penalidade em relação ao erro de ajuste.

- $\alpha = 0$**:** a penalidade desaparece e recupera-se a regressão por mínimos quadrados ordinários, sem regularização.
- α **crescente:** os coeficientes são mais contraídos, reduzindo a flexibilidade do modelo. Pode diminuir o sobreajuste, mas valores excessivos causam subajuste.
- $\alpha \to \infty$**:** na Ridge, os coeficientes penalizados tendem a zero. Com intercepto livre e não penalizado, o modelo tende a prever a média de y do treinamento para qualquer entrada.

Se o intercepto também fosse penalizado, o limite poderia ser diferente. A convenção usual adotada aqui é não penalizá-lo.

Questão 11 | Escala dos atributos na regressão

Qual a importância de normalização ou padronização em um processo de regressão linear múltipla?

Resposta. Colocar os atributos em escalas comparáveis melhora o condicionamento numérico e pode acelerar métodos de otimização, como o gradiente descendente. Duas transformações usuais são

$$\text{padronização: } z_j = \frac{x_j - \mu_j}{\sigma_j}, \qquad \text{min–max: } x'_j = \frac{x_j - \min(x_j)}{\max(x_j) - \min(x_j)}.$$

Na Ridge e no Lasso, a escala é especialmente importante: as penalidades atuam sobre os coeficientes. Um atributo de grande magnitude pode produzir a mesma contribuição à previsão com um coeficiente menor e, sem escalonamento, sofrer menor penalização.

Distinção importante: na regressão por mínimos quadrados sem regularização, com intercepto e solução bem definida, mudar linearmente a escala de um atributo não muda as previsões em aritmética exata; o coeficiente se reajusta. Portanto, não é correto afirmar que uma escala maior sempre faz o atributo dominar esse ajuste.

Médias, desvios e extremos devem ser estimados somente no treinamento e reaplicados à validação e ao teste. Atributos constantes precisam de tratamento para evitar divisão por zero.

Questão 12 | Seleção de atributos com Lasso

A regularização Lasso (L_1) utiliza o valor absoluto dos coeficientes na penalidade. Qual a principal vantagem teórica do Lasso em relação à Ridge quando temos um modelo com muitas variáveis irrelevantes?

Resposta. O Lasso minimiza uma perda com penalidade $\alpha \sum_{j=1}^{p} |\beta_j|$. Essa penalidade pode levar coeficientes a serem **exatamente zero**, produzindo um modelo esparso e realizando seleção de atributos durante o ajuste.

Quando muitas variáveis não ajudam a prever a resposta, essa propriedade pode simplificar o modelo e facilitar sua interpretação. A Ridge usa $\alpha \sum_j \beta_j^2$ e normalmente apenas aproxima os coeficientes de zero, sem eliminá-los exatamente.

A seleção do Lasso não garante identificar todas e somente as variáveis relevantes: depende de α, da quantidade de dados e das correlações entre os atributos.

3 Avaliação e classificação

Questão 13 | Limitações da acurácia

A acurácia é uma métrica suficiente para avaliar um classificador em todas as situações? Justifique com um exemplo onde ela pode ser enganosa e indique qual métrica seria mais adequada.

Resposta. Não. A acurácia é a proporção total de previsões corretas e pode esconder um desempenho ruim na classe minoritária.

Considere 1.000 transações, das quais 10 são fraudulentas. Um classificador que sempre prevê "não fraude" acerta 990 casos e obtém **99% de acurácia**, mas não detecta nenhuma fraude. Considerando fraude como classe positiva, seu recall é

$$\text{Recall} = \frac{VP}{VP + FN} = \frac{0}{0 + 10} = 0.$$

Se a prioridade é detectar fraudes, o **recall da classe positiva** é mais informativo, acompanhado da precisão para monitorar falsos alarmes. A precisão é $VP/(VP+FP)$; nesse exemplo, seu denominador é zero, sendo comum defini-la como zero por convenção computacional.

Quando se deseja equilibrar precisão e recall, pode-se usar $F_1 = 2VP/(2VP+FP+FN)$, que também é zero nesse caso. A métrica deve refletir os custos dos erros e o objetivo da aplicação.

Questão 14 | AUC-ROC

O que representa a AUC-ROC e qual é sua interpretação probabilística? O que significa um modelo com AUC = 0,5? E um com AUC = 1,0?

Resposta. A curva ROC relaciona a taxa de verdadeiros positivos, TPR $= VP/(VP + FN)$, à taxa de falsos positivos, FPR $= FP/(FP + VN)$, ao variar o limiar de decisão. A **AUC-ROC** é a área sob essa curva e resume a capacidade de ordenar positivos acima de negativos.

Se s^+ é o escore de um positivo aleatório e s^- o de um negativo aleatório, então

$$\text{AUC} = P(s^+ > s^-) + \frac{1}{2}P(s^+ = s^-).$$

Sem empates, é a probabilidade de um positivo receber escore maior que um negativo.

- **AUC** $= 0{,}5$**:** desempenho global de ordenação equivalente ao aleatório segundo essa métrica. Isso não exige que o algoritmo faça sorteios nem que toda a curva ROC coincida com a diagonal.
- **AUC** $= 1$**:** separação perfeita dos escores das duas classes no conjunto avaliado; todo positivo recebe escore maior que todo negativo.

AUC igual a 1 não garante generalização perfeita nem probabilidades bem calibradas. AUC avalia ordenação, não calibração ou desempenho de um limiar específico.

Questão 15 | Validação cruzada K-Fold

Explique o conceito de validação cruzada K-Fold. Explique como ela pode ser utilizada para o ajuste dos hiperparâmetros de um modelo.

Resposta. Divide-se o conjunto disponível para desenvolvimento em K subconjuntos, chamados *folds*. Em cada uma das K rodadas, ajusta-se o modelo em $K - 1$ folds e calcula-se a métrica no fold restante. Cada observação participa da validação uma vez.

Para cada configuração candidata de hiperparâmetros, repete-se o procedimento e calcula-se a média das métricas de validação. Escolhe-se a configuração com melhor desempenho segundo o critério adotado. Por exemplo, comparam-se diferentes valores de k do k-NN pela acurácia média de validação.

Em seguida, reajusta-se a configuração escolhida em todos os dados de desenvolvimento e avalia-se uma única vez no teste reservado. O pré-processamento deve ser ajustado separadamente dentro de cada rodada, usando apenas os folds de treinamento.

Em classificação, folds estratificados ajudam a preservar as proporções das classes. Dados temporais ou agrupados exigem divisões apropriadas, em vez de um K-Fold aleatório comum.

Questão 16 | Treinamento e latência de previsão

Qual é a principal diferença entre o k-NN e a regressão logística no que diz respeito à fase de treinamento? Qual técnica seria mais adequada em um cenário com uma grande base de treinamento e um requisito de baixa latência para previsões?

Resposta. O **k-NN** é um método de aprendizagem preguiçosa: seu ajuste consiste principalmente em armazenar os exemplos, podendo construir uma estrutura de busca. O trabalho de localizar vizinhos ocorre na previsão. Uma busca exata por força bruta custa aproximadamente $O(np)$ por consulta, com n exemplos e p atributos.

A **regressão logística** aprende coeficientes por otimização durante o treinamento. Na classificação binária, uma previsão usa $\sigma(\beta_0 + \mathbf{x}^\top \boldsymbol{\beta})$, em que $\sigma(z) = 1/(1 + e^{-z})$, com custo aproximadamente $O(p)$.

Entre as duas, a **regressão logística** tende a ser mais adequada para uma base grande e baixa latência, porque o custo da previsão não cresce diretamente com o número de exemplos de treinamento. A qualidade preditiva deve ser verificada; índices ou buscas aproximadas podem acelerar o k-NN.

Questão 17 | Classificação com k-NN

Explique, de forma resumida, as etapas envolvidas no processo de classificação de uma nova instância usando o algoritmo k-NN.

Resposta.

1. Aplicar à nova instância o mesmo pré-processamento ajustado no treinamento, como a padronização dos atributos.
2. Calcular sua distância aos exemplos de treinamento segundo a métrica escolhida, por exemplo, a euclidiana.
3. Selecionar os k exemplos mais próximos.
4. Agregar seus rótulos por votação majoritária ou por votação ponderada, dando maior peso aos vizinhos mais próximos.
5. Atribuir a classe vencedora. Se houver empate, utilizar uma regra previamente definida.

O valor de k e a métrica de distância são hiperparâmetros. Por exemplo, se os cinco vizinhos têm rótulos A, A, B, A e B, a votação majoritária prevê A.

4 Árvores de decisão

Questão 18 | Estrutura de uma árvore de decisão

Defina árvore de decisão como modelo de aprendizado de máquina e descreva seus componentes estruturais (raiz, nós internos e folhas).

Resposta. Uma **árvore de decisão** é um modelo supervisionado que divide recursivamente o espaço de atributos por meio de testes. Para prever, uma observação percorre um caminho da raiz até uma folha, de acordo com os resultados dos testes.

- **Raiz:** nó inicial, que recebe todos os exemplos de treinamento e, quando há divisão, contém o primeiro teste.
- **Nós internos:** contêm testes sobre atributos, como "renda $\leq t$?". Cada ramo corresponde a um resultado do teste e leva a um subconjunto dos exemplos.
- **Folhas:** nós terminais que fornecem a previsão. Em classificação, normalmente apresentam a classe majoritária e/ou as proporções das classes; em regressão com perda quadrática, a média das respostas dos exemplos da folha.

Cada caminho define uma regra de decisão. Uma árvore sem divisões tem apenas a raiz, que também é uma folha.

Questão 19 | Entropia de Shannon

Defina matematicamente a entropia de Shannon e explique seu comportamento em nós puros e em nós com distribuição uniforme das classes.

Resposta. Se um nó possui C classes possíveis e proporção p_c de exemplos da classe c, sua entropia é

$$H = -\sum_{c=1}^{C} p_c \log_2 p_c, \qquad \text{com } 0 \log_2 0 = 0.$$

Ela mede a incerteza sobre a classe de um exemplo escolhido no nó.

- **Nó puro:** uma classe tem probabilidade 1 e as demais 0. Portanto, $H = 0$; não há incerteza sobre a classe.
- **Distribuição uniforme:** $p_c = 1/C$ para todas as classes. A entropia atinge seu máximo, $H = \log_2 C$.

No caso binário, um nó com proporções $(1, 0)$ tem entropia zero; um nó com proporções $(0{,}5, 0{,}5)$ tem entropia de 1 bit. Maior mistura entre classes corresponde a maior entropia.

Questão 20 | Impureza de Gini

Defina a impureza de Gini e compare-a com a entropia de Shannon em termos de propriedades e uso prático.

Resposta. Para proporções de classe $p_1, \ldots, p_C$, a impureza de Gini é

$$G = 1 - \sum_{c=1}^{C} p_c^2 = \sum_{c=1}^{C} p_c(1 - p_c).$$

Ela corresponde à probabilidade de duas classes sorteadas independentemente segundo a distribuição do nó serem diferentes.

Assim como a entropia, o Gini é zero em nós puros e máximo quando as classes estão uniformemente distribuídas. Seu máximo é $1 - 1/C$, enquanto o máximo da entropia é $\log_2 C$. Para duas classes igualmente frequentes, $G = 0{,}5$ e $H = 1$ bit.

Ambos podem avaliar a qualidade de divisões em árvores de classificação pela redução ponderada de impureza. O Gini dispensa logaritmos e tem cálculo mais simples. A entropia apresenta maior sensibilidade a mudanças em proporções próximas de zero. Na prática, frequentemente produzem árvores semelhantes, mas não necessariamente escolhem as mesmas divisões.

Questão 21 | Ganho de informação

O que é o ganho de informação e como ele é utilizado para escolher o melhor atributo de divisão em cada nó?

Resposta. O ganho de informação é a redução da entropia proporcionada por uma divisão. Para um conjunto S no nó pai e subconjuntos filhos $S_1, \ldots, S_m$,

$$IG = H(S) - \sum_{r=1}^{m} \frac{|S_r|}{|S|} H(S_r).$$

A entropia de cada filho é ponderada pela proporção de exemplos que ele recebe. O algoritmo avalia as divisões candidatas e escolhe o atributo e, quando necessário, o limiar que proporcionam o **maior ganho**, respeitando as restrições de crescimento.

Exemplo: um nó com 10 exemplos, cinco de cada classe, tem entropia 1 bit. Se uma divisão gera dois filhos puros de cinco exemplos, a entropia ponderada após a divisão é zero e o ganho é 1 bit. Se ambos mantiverem a proporção 50%/50%, o ganho será zero.

Quando se usa Gini no lugar da entropia, o critério análogo é a redução ponderada da impureza de Gini.

Questão 22 | Critérios de parada de árvores

Quais são os critérios de parada usados na construção de uma árvore de decisão e qual a importância de cada um para evitar o overfitting?

Resposta. Os critérios mais comuns são:

- **Nó puro:** todos os exemplos pertencem à mesma classe. Não há impureza de classificação a reduzir.
- **Profundidade máxima:** limita o número de testes consecutivos e evita regras muito específicas.
- **Número mínimo de exemplos para dividir:** impede novas divisões em nós com poucos dados, cujas decisões seriam instáveis.
- **Número mínimo de exemplos por folha:** rejeita divisões que produzam folhas pequenas demais, reduzindo a memorização de casos isolados.
- **Ganho mínimo de impureza:** só aceita uma divisão se a melhoria atingir um limiar, evitando crescimento com benefício muito pequeno.
- **Número máximo de folhas:** limita a complexidade total da árvore.
- **Ausência de divisão válida:** encerra o crescimento quando não existe teste capaz de separar os exemplos sob as restrições adotadas, como quando todos têm os mesmos atributos.

Essas restrições constituem formas de **pré-poda** e devem ser ajustadas por validação. Parar cedo demais pode causar subajuste. Outra estratégia é a **pós-poda**: crescer a árvore e depois remover ramos cujo benefício não justifica sua complexidade.

Questão 23 | Atributos numéricos e limiares

Como uma árvore de decisão lida com atributos numéricos e qual o procedimento para encontrar o melhor limiar (threshold) de divisão?

Resposta. Para um atributo numérico x_j, uma divisão binária usa o teste $x_j \leq t$. Exemplos que satisfazem o teste seguem para um filho; os demais, para o outro.

1. Ordenar os valores do atributo presentes no nó e identificar valores distintos consecutivos $v_r < v_{r+1}$.
2. Considerar limiares candidatos entre esses valores, normalmente os pontos médios $t_r = (v_r + v_{r+1})/2$.
3. Para cada candidato, formar os dois grupos e calcular a impureza ponderada dos filhos, usando entropia ou Gini em classificação.
4. Descartar divisões que violem restrições, como o tamanho mínimo de uma folha.

5. Escolher o limiar com maior redução de impureza. Comparar também os melhores resultados dos demais atributos para selecionar a divisão do nó.

Por exemplo, para valores distintos 2, 4 e 9, os limiares candidatos são 3 e 6,5. Valores iguais não são separados por um mesmo teste de limiar.

5 Clusterização e k-means

Questão 24 | Clusterização e classificação

O que é clusterização e em que aspecto fundamental ela se diferencia da classificação supervisionada?

Resposta. **Clusterização** é o agrupamento de observações de acordo com alguma noção de semelhança ou estrutura, buscando grupos coerentes. Na formulação usual, é uma tarefa não supervisionada: os dados não trazem os rótulos dos grupos que devem ser aprendidos.

A **classificação supervisionada** aprende a atribuir categorias previamente definidas a partir de exemplos rotulados. Por exemplo, descobrir perfis de clientes por comportamento de compra é clusterização; prever se um cliente cancelará o serviço usando exemplos históricos rotulados é classificação.

A distinção fundamental é a presença de rótulos-alvo no treinamento. Os grupos descobertos por clusterização não precisam coincidir com classes conhecidas ou ter um significado previamente definido.

Questão 25 | Qualidade de uma clusterização

O que caracteriza uma boa clusterização e quais são as características desejáveis de um método ideal de clusterização?

Resposta. Em uma boa clusterização, os objetos de um mesmo grupo são semelhantes entre si (**coesão**) e objetos de grupos diferentes são distintos (**separação**), de acordo com a medida de similaridade e o objetivo da análise. Os grupos também devem ser interpretáveis e úteis no contexto da aplicação.

São características desejáveis de um método:

- escalabilidade para grandes volumes de dados;
- capacidade de tratar os tipos de atributos relevantes, inclusive dados mistos;
- robustez a ruído e outliers;
- capacidade de reconhecer grupos com diferentes formas, tamanhos e densidades;
- estabilidade diante da ordem dos dados, da inicialização e de pequenas perturbações;
- bom comportamento em alta dimensionalidade;
- poucos parâmetros difíceis de definir e possibilidade de incorporar conhecimento do domínio;
- resultados compreensíveis e custo computacional adequado.

Não existe um método universalmente melhor: coesão e separação dependem da geometria adotada. Grupos alongados ou não convexos, por exemplo, podem ser válidos mesmo sem serem compactos ao redor de uma média.

Questão 26 | Algoritmo k-means

Descreva detalhadamente o algoritmo k-means, enunciando cada uma de suas etapas e a condição de convergência.

Resposta. O k-means divide n observações numéricas em k grupos e busca minimizar a soma dos quadrados das distâncias aos respectivos centroides:

$$J = \sum_{j=1}^{k} \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2.$$

O algoritmo usual de Lloyd segue estas etapas:

1. **Preparação:** escolher os atributos, tratar dados problemáticos e ajustar suas escalas quando necessário. Definir o número de grupos k.
2. **Inicialização:** escolher k centroides iniciais, por amostragem de observações ou por uma estratégia como k-means++.
3. **Atribuição:** associar cada observação ao centroide mais próximo:

$$c_i = \arg\min_{1 \le j \le k} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2.$$

4. **Atualização:** recalcular cada centroide como a média dos pontos atribuídos ao grupo:

$$\boldsymbol{\mu}_j = \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i.$$

   Se um grupo ficar vazio, é necessário aplicar uma regra de tratamento, como realocar seu centroide para uma observação distante.

5. **Repetição:** alternar atribuição e atualização até a estabilização.

A convergência exata ocorre quando as atribuições não mudam e os centroides permanecem iguais, sob uma regra consistente de desempate. Na prática, usa-se uma tolerância para o deslocamento dos centroides ou a melhoria de J, além de um limite de iterações. Atingir esse limite não significa necessariamente convergir.

As duas etapas centrais não aumentam J, que é limitado inferiormente por zero. O resultado é uma solução estável, em geral local, e não há garantia de ótimo global. Executar várias inicializações e manter a de menor J reduz a dependência da inicialização.

Questão 27 | Limitações do k-means

Quais são as principais limitações do algoritmo k-means? Para cada limitação, indique o tipo de dado ou situação em que ela se manifesta.

Resposta.

1. **Exige definir k:** ocorre quando não se conhece o número de grupos, como em segmentação exploratória. Um valor inadequado funde grupos diferentes ou fragmenta um mesmo grupo.
2. **Favorece grupos compactos e aproximadamente esféricos:** falha em luas entrelaçadas, anéis e grupos muito alongados, porque a atribuição ao centroide mais próximo cria regiões de Voronoi convexas no espaço euclidiano.

3. **Dificuldade com tamanhos e densidades muito diferentes:** um grupo grande e disperso pode receber vários centroides, enquanto grupos pequenos próximos podem ser fundidos, pois o objetivo minimiza o erro quadrático total.
4. **Sensibilidade a outliers:** valores extremos deslocam a média e pesam muito na distância ao quadrado. Isso aparece em dados com erros de medição ou valores raros muito elevados.
5. **Sensibilidade à escala:** em dados com renda em reais e idade em anos, a renda pode dominar as distâncias por sua magnitude numérica se as escalas não forem ajustadas.
6. **Dependência da inicialização:** diferentes centroides iniciais podem levar a soluções locais distintas em dados com partições concorrentes.
7. **Restrição a uma geometria numérica adequada:** médias e distâncias euclidianas não representam naturalmente atributos nominais, como cor ou profissão. Codificá-los por números arbitrários introduz distâncias artificiais.
8. **Alta dimensionalidade:** muitos atributos irrelevantes ou redundantes podem tornar as distâncias pouco informativas e esconder os grupos.

Além disso, o k-means atribui todos os pontos a algum grupo: não identifica explicitamente uma classe de ruído.

Questão 28 | Matriz de dissimilaridade e distâncias

Defina a matriz de dissimilaridade e liste pelo menos cinco métricas de distância utilizadas em problemas de clusterização.

Resposta. A **matriz de dissimilaridade** $D \in \mathbb{R}^{n\times n}$ armazena em cada posição $D_{ij} = d(\mathbf{x}_i, \mathbf{x}_j)$ o grau de diferença entre as observações i e j. Valores menores indicam maior semelhança. Para uma distância métrica, $D_{ij} \geq 0$, $D_{ii} = 0$ e $D_{ij} = D_{ji}$; a função também satisfaz a desigualdade triangular. Uma dissimilaridade genérica não precisa satisfazer todas as propriedades de uma métrica.

Cinco exemplos de métricas são:

1. **Euclidiana:** $d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{r=1}^{p}(x_r - y_r)^2}$. Mede distância em linha reta em espaços numéricos.
2. **Manhattan:** $d(\mathbf{x}, \mathbf{y}) = \sum_{r=1}^{p} |x_r - y_r|$. Soma as diferenças absolutas por coordenada.
3. **Chebyshev:** $d(\mathbf{x}, \mathbf{y}) = \max_r |x_r - y_r|$. Considera a maior diferença entre coordenadas.
4. **Hamming:** $d(\mathbf{x}, \mathbf{y}) = \sum_{r=1}^{p} \mathbb{1}(x_r \neq y_r)$. Conta posições diferentes em sequências ou vetores categóricos de mesmo comprimento; também pode ser normalizada por p.
5. **Jaccard:** $d(A, B) = 1 - |A \cap B|/|A \cup B|$, para conjuntos com união não vazia; define-se $d(\varnothing, \varnothing) = 0$. É útil para conjuntos de itens e atributos binários de presença/ausência, sem valorizar ausências conjuntas.

A escolha depende do tipo de dado e da noção de semelhança desejada. O k-means clássico usa distâncias euclidianas ao quadrado em sua função objetivo; não basta substituir essa distância por qualquer outra e manter a atualização pela média.

Questão 29 | Escalonamento antes do k-means

Por que é recomendável normalizar os dados antes de aplicar o k-means e qual técnica é mais comumente utilizada?

Resposta. O k-means depende de distâncias euclidianas. Se os atributos têm escalas muito diferentes, aqueles com maior amplitude ou variância podem dominar o cálculo, mesmo sem serem mais relevantes. Por exemplo, diferenças de milhares de reais em renda podem se sobrepor a diferenças de algumas décadas em idade.

Uma técnica muito utilizada é a **padronização por escore-z**:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j},$$

em que μ_j e σ_j são a média e o desvio padrão do atributo j. Cada atributo não constante passa a ter média zero e variância unitária segundo a convenção utilizada.

Outra opção comum é a normalização min–max para $[0, 1]$. A escolha depende do problema; a padronização não elimina outliers nem garante grupos melhores em toda situação. Se as escalas originais expressarem pesos relevantes do domínio, modificá-las também modifica a noção de semelhança. Atributos constantes devem ser removidos ou tratados separadamente.

Questão 30 | Três situações de falha do k-means

Descreva três situações práticas em que o algoritmo k-means falha em produzir uma boa clusterização e explique o motivo em cada caso.

Resposta.

1. **Pontos formando dois anéis concêntricos ou duas luas.** Os grupos reais são não convexos. A regra de proximidade a centroides produz fronteiras lineares entre pares de grupos e tende a cortar essas formas em partes, misturando pontos de grupos reais diferentes. Métodos baseados em densidade ou em grafos podem representar melhor essa geometria.
2. **Clientes com perfis usuais e poucos valores extremos de renda ou gasto.** Como o centroide é uma média e o objetivo usa distâncias ao quadrado, os extremos atraem os centroides ou consomem um grupo para representar poucos pontos, prejudicando os perfis predominantes. Tratamento criterioso de extremos ou métodos como k-medoids podem ser mais adequados.
3. **Um grupo grande e disperso junto de pequenos grupos compactos.** Reduzir o erro quadrático do grupo grande pode ser mais vantajoso para o objetivo do algoritmo do que preservar cada grupo pequeno. Assim, ele pode dividir o grupo grande e fundir os pequenos, principalmente quando próximos. Modelos com covariâncias próprias por grupo ou métodos adaptados à densidade podem representar melhor essa estrutura.

Nos três casos, a falha decorre de uma incompatibilidade entre a estrutura desejada e o objetivo geométrico do k-means; aumentar o número de iterações não resolve essa incompatibilidade.